

小白入门教程 · 拟定目录（预备稿，未撰写）

定位：面向零基础读者的"AI 安全（LLM / CV / 具身）"入门教程。目标是读完能画出系统边界、说清攻击从哪进、防御放在哪，并知道证据能支持到哪一层。

原则：每讲一个主问题；先直觉后术语；攻击内容止步机制层（配合仓库 SECURITY.md）；数字必带分母。

第 0 讲 先建三个直觉（导读）

- 一句输出、一个计划、一次执行、一个现实后果，不是一回事
- "模型被越狱"≠"系统被攻破"：五层后果链的白话版
- 素材：书稿第 1 章开篇四例（文字/视频/机器人/世界模型）

第 1 讲 共同语言：系统、接口与第一次失守

- 内容、决策输入、执行参数三种输出地位
- 首破接口（U0-U6 的白话版）与"最高观测层/最高可达层"
- 术语表登场（附录 D 的 131 条，按讲次分发）
- 素材：书稿第 1-3 章；自绘图 fig-01-01 能力链、fig-01-02 四泳道

第 2 讲 LLM 与智能体安全：越狱、提示注入与"会说话的程序"

- 越狱 vs 提示注入之别；间接注入：网页/邮件/PDF 怎么变成指令
- RAG 投毒、记忆持久化：一次输入如何影响明天
- 工具、身份、沙盒：危险意图 ≠ 危险执行（HF 事件白话复盘）
- 素材：LLMSE §1.1、§3.1、§3.3-3.6、§7；书稿第 4-7 章

第 3 讲 CV / 生成式视觉安全：从训练数据到发布链

- 生成管线最小模型：潜变量、扩散、条件、时间状态（技术脉络白话版）
- 攻击从哪来：数据投毒、后门、条件越狱、提取与伪造
- 防御从哪放：检测、水印、内容来源与真实性链（能证明什么/不能证明什么）
- 素材：Ditse_v2 第 3/5/7 章（I1-I7 白话化）；Ditvid 技术谱系选段

第 4 讲 具身与世界模型安全：从"看错"到"做错"

- VLM / VLA / WAM 按接口区分（名称不等于能力）
- 误差如何沿"观察—语义—计划—动作—反馈"传播
- WM / EWM / WAM / WCM 四类合同白话表；想象链怎样被劫持

- 素材：wmse 概念合同表与攻击链；VW 05 攻击故事（去公式）、06 防御镜像、07 安全壳

第 5 讲 工程闭环：把知识变成检查清单

- 威胁建模 → 测试矩阵 → 发布门 → 监控 → 事故响应
- 四联报告：攻击效果、正常效用、成本、后果
- 每讲一图一清单收尾：第 0-5 讲的防御检查清单合集
- 素材：书稿第 19-20 章；LLMSE §11 工程清单

附录（成稿时随教程发布）

- A 术语表（源自书稿附录 D，131 条中英对照）
- B 每讲防御检查清单（源自各综述的防御章节重排）
- C 延伸阅读（指向本发布区 01-04 的进阶材料与原始论文）